

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - TIN HỌC



ĐỒ ÁN CUỐI KỲ
HỌC PHẦN DỰ BÁO

Giảng viên bộ môn: TS. Nguyễn Tiến Đạt

Họ và tên	MSSV	Lớp
Đỗ Nam Anh (Nhóm trưởng)	23110130	23TTH2
Hoàng Nguyễn Bá Việt	23110122	23TTH2
Võ Công Danh	23110139	23TTH2

TP. Hồ Chí Minh, 01/2026

MỤC LỤC

Lời cảm ơn	1
Tóm tắt	2
I Mở đầu	3
II Phân chia công việc và đánh giá mức độ hoàn thành	3
IIIBài tập Lý thuyết	3
Bài 1	3
Bài 2	4
Bài 3	7
Bài 4	8
Bài 5	10
Bài 6	12
IV Bài tập thực hành	15
Bài thực hành 1	15
Bài thực hành 2	25
Bài thực hành 3	38
V Tài liệu tham khảo	46

LỜI CẢM ƠN

Xin chân thành cảm ơn **Khoa Toán - Tin học** Trường Đại học Khoa học Tự nhiên đã hỗ trợ giảng dạy chuyên môn, đồng thời cung cấp cơ sở vật chất cho chúng em trong quá trình học tập.

Xin cảm ơn các thầy cô bộ môn, đặc biệt là **TS Nguyễn Tiến Đạt** - giảng viên môn Dự Báo - đã hướng dẫn tận tình và cung cấp những kiến thức cần thiết về môn học cho nhóm chúng em trong quá trình học tập và hoàn thành đồ án này.

Cuối cùng, chúng em gửi lời cảm ơn đến các thành viên trong nhóm đã cùng nhau làm việc nghiêm túc để hoàn thành báo cáo.

Nhóm sinh viên thực hiện

Tháng 1 năm 2025

TÓM TẮT

Trong nghiên cứu này, nhóm chúng em tập trung phân tích các lý thuyết về **Mô hình hồi quy tuyến tính bội**, **TIME SERIES**, và **Mô hình ARIMA và SARIMA** để ứng dụng giải bài tập lý thuyết và đưa ra mô hình dự báo cho bộ dữ liệu . Báo cáo trình bày:

- Cơ sở lý thuyết của bài toán mô hình hồi quy tuyến tính và TIME SERIES
- Triển khai ứng dụng bằng ngôn ngữ **R**.
- Đánh giá kết quả và đưa ra các dự báo trong tương lai cho bộ dữ liệu

Từ khóa: Dự báo , mô hình hồi quy tuyến tính, ngôn ngữ lập trình R.

I Mở đầu

Trong thời đại dữ liệu hiện nay, dự báo đóng vai trò then chốt trong việc hỗ trợ ra quyết định và hoạch định chiến lược. Đồ án này được thực hiện nhằm mục đích ứng dụng các kiến thức toán học từ môn Dự báo vào thực tiễn thông qua hai phương pháp chính: **Mô hình Hồi quy tuyến tính bội** và **Mô hình Chuỗi thời gian (Time Series)**.

II Phân chia công việc và đánh giá mức độ hoàn thành

PHÂN CÔNG NHIỆM VỤ VÀ TIẾN ĐỘ HOÀN THÀNH

STT	Họ và tên	MSSV	Nhiệm vụ được phân công	Tiến độ hoàn thành
1	Đỗ Nam Anh	23110130	Bài tập lý thuyết, Bài tập thực hành 1, Báo cáo	100%
2	Hoàng Nguyễn Bá Việt	23110122	Bài tập lý thuyết, Bài tập thực hành 3, Báo cáo	100%
3	Võ Công Danh	23110139	Bài tập lý thuyết, Bài tập thực hành 2, Báo cáo	100%

III Bài tập Lý thuyết

Measure of dependence

Bài 1

Chứng minh rằng hàm autocovariance có thể được viết lại thành

$$\gamma_X(s, t) \equiv \gamma_X(s, t) = \mathbb{E}[(X_s - \mu_s)(X_t - \mu_t)] = \mathbb{E}(X_s X_t) - \mu_s \mu_t, \quad \text{với } \mathbb{E}(X_t) = \mu_t.$$

Giải

Với $\mathbb{E}(X_t) = \mu_t$, ta cũng có $\mathbb{E}(X_s) = \mu_s$.

Từ định nghĩa hàm auto-covariance, ta có:

$$\begin{aligned} \gamma_X(s, t) &= \text{Cov}(X_s, X_t) = \mathbb{E}[(X_s - \mathbb{E}(X_s))(X_t - \mathbb{E}(X_t))] \\ &= \mathbb{E}[(X_s - \mu_s)(X_t - \mu_t)] \\ &= \mathbb{E}(X_s X_t) - \mu_s \mathbb{E}(X_t) - \mu_t \mathbb{E}(X_s) + \mu_s \mu_t \\ &= \mathbb{E}(X_s X_t) - \mu_s \mu_t - \mu_t \mu_s + \mu_s \mu_t \\ &= \mathbb{E}(X_s X_t) - \mu_s \mu_t \end{aligned}$$

Vậy ta đã chứng minh được $\gamma_X(s, t) = \mathbb{E}[(X_s - \mu_s)(X_t - \mu_t)] = \mathbb{E}(X_s X_t) - \mu_s \mu_t$.

Stationary time series

Bài 2

Xét time series

$$X_t = \beta_1 + \beta_2 t + W_t ,$$

trong đó β_1 và β_2 là các hằng số đã biết, còn W_t là white noise với $\text{Var}(W_t) = \sigma_W^2$.

- (a) X_t có phải là quá trình dừng (stationary process) hay không?
- (b) Chứng tỏ rằng $Y_t := X_t - X_{t-1}$ là một quá trình dừng.
- (c) Xét **moving-average** series V_t với

$$V_t := \frac{1}{2q+1} \sum_{j=-q}^q X_{t-j} . \quad (1)$$

Chứng tỏ rằng hàm trung bình của **moving-average** V_t là $\mu_{V_t} = \beta_1 + \beta_2 t$, và hãy tính hàm autocovariance của V_t .

Giải

- a) Xét hàm trung bình của X_t :

$$\begin{aligned} \mu_{X_t} &= E(X_t) = E(\beta_1 + \beta_2 t + W_t) \\ &= \beta_1 + \beta_2 t + E(W_t) \\ &= \beta_1 + \beta_2 t + 0 \\ &= \beta_1 + \beta_2 t \end{aligned}$$

Nhận xét: Hàm trung bình của X_t là một hàm phụ thuộc vào biến t .

Kết luận: X_t không là quá trình dừng.

- b) Ta có:

$$X_t = \beta_1 + \beta_2 t + W_t \text{ nên } X_{t-1} = \beta_1 + \beta_2(t-1) + W_{t-1}$$

$$\begin{aligned} Y_t &= X_t - X_{t-1} = \beta_1 + \beta_2 t + W_t - (\beta_1 + \beta_2(t-1) + W_{t-1}) \\ &= \beta_2 t + W_t - \beta_2(t-1) - W_{t-1} \\ &= \beta_2 + W_t - W_{t-1} \end{aligned}$$

Xét hàm trung bình của Y_t :

$$\begin{aligned}\mu_t(Y_t) &= E(Y_t) = E(\beta_2 + W_t - W_{t-1}) \\ &= \beta_2 + E(W_t) - E(W_{t-1}) \\ &= \beta_2 + 0 - 0 \\ &= \beta_2\end{aligned}$$

Nhận xét: Hàm trung bình của Y_t không phụ thuộc vào biến thời gian t .

(1)

Xét hàm auto-covariance của Y_t :

$$\begin{aligned}\gamma_Y(t, s) &= \text{Cov}(Y_t, Y_s) \\ &= \text{Cov}(\beta_2 + W_t - W_{t-1}, \beta_2 + W_s - W_{s-1}) \\ &= \text{Cov}(W_t - W_{t-1}, W_s - W_{s-1}) \\ &= \text{Cov}(W_t, W_s) - \text{Cov}(W_t, W_{s-1}) - \text{Cov}(W_{t-1}, W_s) + \text{Cov}(W_{t-1}, W_{s-1})\end{aligned}$$

Với $t = s$:

$$\gamma_Y(t, s) = \text{Cov}(W_t, W_s) + \text{Cov}(W_{t-1}, W_{s-1}) = 2\sigma_W^2$$

Với $t - s = -1$:

$$\gamma_Y(t, s) = -\text{Cov}(W_t, W_{s-1}) = -\sigma_W^2$$

Với $t - s = 1$:

$$\gamma_Y(t, s) = -\text{Cov}(W_{t-1}, W_s) = -\sigma_W^2$$

Hàm auto-covariance của Y_t là:

$$\gamma_Y(t, s) = \begin{cases} 2\sigma_W^2 & , \text{ nếu } t = s \\ -\sigma_W^2 & , \text{ nếu } |t - s| = 1 \\ 0 & , \text{ nếu } |t - s| > 1 \end{cases}$$

Nhận xét: Hàm auto-covariance của Y_t chỉ phụ thuộc vào khoảng cách t và s .

(2)

Kết luận: Từ (1) và (2) kết luận $Y_t := X_t - X_{t-1}$ là một quá trình dừng.

c)

Xét moving-average series V_t với $V_t := \frac{1}{2q+1} \sum_{j=-q}^q X_{t-j}$

Hàm trung bình của moving-average series V_t

$$\begin{aligned}
\mu_{V_t} = E(V_t) &= E\left(\frac{1}{2q+1} \sum_{j=-q}^q X_{t-j}\right) \\
&= \frac{1}{2q+1} E\left(\sum_{j=-q}^q X_{t-j}\right) \\
&= \frac{1}{2q+1} E\left(\sum_{j=-q}^q \beta_1 + \beta_2(t-j) + W_{t-j}\right) \\
&= \frac{1}{2q+1} \left(\sum_{j=-q}^q \beta_1 + \sum_{j=-q}^q \beta_2 t - \sum_{j=-q}^q \beta_2 j + E\left(\sum_{j=-q}^q W_{t-j}\right)\right) \\
&= \frac{1}{2q+1} ((2q+1)\beta_1 + (2q+1)\beta_2 t - 0 + 0) \\
&= \beta_1 + \beta_2 t
\end{aligned}$$

Hàm auto-covariance của V_t

$$\begin{aligned}
\gamma_V(t, s) &= \text{Cov}(V_t, V_s) \\
&= \text{Cov}\left(\frac{1}{2q+1} \sum_{j=-q}^q X_{t-j}, \frac{1}{2q+1} \sum_{k=-q}^q X_{s-k}\right) \\
&= \frac{1}{(2q+1)^2} \sum_{j=-q}^q \sum_{k=-q}^q \text{Cov}(X_{t-j}, X_{s-k})
\end{aligned}$$

Ta có:

$$\text{Cov}(V_{t-j}, V_{s-k}) = E[(V_{t-j} - E(V_{t-j}))(V_{s-k} - E(V_{s-k}))] = \text{Cov}(W_{t-j}, W_{s-k})$$

Hàm auto-covariance của V_t được viết lại thành:

$$\gamma_V(t, s) = \frac{1}{(2q+1)^2} \sum_{j=-q}^q \sum_{k=-q}^q \text{Cov}(W_{t-j}, W_{s-k})$$

Với $t = s$:

$$\begin{aligned}
\gamma_V(t, s) &= \frac{1}{(2q+1)^2} \sum_{j=-q}^q \sum_{k=-q}^q \text{Cov}(W_{t-j}, W_{t-k}) \\
&= \frac{2q+1}{(2q+1)^2} \sigma_W^2
\end{aligned}$$

Với $|t - s| = 1$:

$$\gamma_V(t, s) = \frac{1}{(2q+1)^2} \sum_{j=-q}^q \sum_{k=-q}^q \text{Cov}(W_{t-j}, W_{t-(k+1)}) = \frac{2q}{(2q+1)^2} \sigma_W^2$$

Với $|t - s| = 2$:

$$\gamma_V(t, s) = \frac{1}{(2q+1)^2} \sum_{j=-q}^q \sum_{k=-q}^q \text{Cov}(W_{t-j}, W_{t-(k+2)}) = \frac{2q-1}{(2q+1)^2} \sigma_W^2$$

Với $|t - s| = 2q$:

$$\gamma_V(t, s) = \frac{1}{(2q+1)^2} \sum_{j=-q}^q \sum_{k=-q}^q \text{Cov}(W_{t-j}, W_{t-(k+2q)}) = \frac{1}{(2q+1)^2} \sigma_W^2$$

Hàm auto-covariance của V_t là:

$$\gamma_V(t, s) = \begin{cases} \frac{2q+1}{(2q+1)^2} \sigma_W^2 & , \text{ nếu } t = s \\ \frac{2q}{(2q+1)^2} \sigma_W^2 & , \text{ nếu } |t - s| = 1 \\ \frac{2q-1}{(2q+1)^2} \sigma_W^2 & , \text{ nếu } |t - s| = 2 \\ \frac{1}{(2q+1)^2} \sigma_W^2 & , \text{ nếu } |t - s| = 2q \\ 0 & , \text{ nếu } |t - s| > 2q \end{cases}$$

Bài 3

Hai time series X_t và Y_t gọi là dừng đồng thời (*jointly stationary*) nếu X_t và Y_t là các time series dừng, và xét hàm cross-covariance, với $h = \{0, \pm 1, \pm 2, \dots\}$,

$$\gamma_{X;Y}(h) = \text{Cov}(X_{t+h}, Y_t) = \mathbb{E}[(X_{t+h} - \mathbb{E}(X_t))(Y_t - \mathbb{E}(Y_t))],$$

thì hàm cross-covariance $\gamma_{X;Y}(h)$ chỉ phụ thuộc vào h (KHÔNG phụ thuộc giá trị cụ thể của t).

■ Cho X_t và Y_t là hai quá trình dừng đồng thời (*jointly stationary*). Xét hàm **cross-correlation** (CCF)

$$\rho_{X;Y}(h) := \frac{\gamma_{X;Y}(h)}{\sqrt{\gamma_X(0) \times \gamma_Y(0)}}.$$

Chứng minh $\rho_{Y;X}(-h) = \rho_{X;Y}(h)$ với mọi $h = \{0, \pm 1, \pm 2, \dots\}$.

Giải

Ta có:

$$\rho_{X;Y}(h) = \frac{\gamma_{X;Y}(h)}{\sqrt{\gamma_X(0) \gamma_Y(0)}} \quad \text{và} \quad \rho_{Y;X}(-h) = \frac{\gamma_{Y;X}(-h)}{\sqrt{\gamma_X(0) \gamma_Y(0)}}$$

Để chứng minh $\rho_{X;Y}(h) = \rho_{Y;X}(-h)$, ta cần chứng minh $\gamma_{X;Y}(h) = \gamma_{Y;X}(-h)$.

Giả thiết X_t, Y_t là hai quá trình dừng đồng thời, nên hàm $\gamma_{X;Y}(h)$ chỉ phụ thuộc vào h .

Nghĩa là:

$$\gamma_{X;Y}(h) = \text{Cov}(X_{t+h}, Y_t) = \text{Cov}(X_t, Y_{t-h})$$

Với $h = \{0, \pm 1, \pm 2, \dots\}$, ta có:

$$\begin{aligned}\gamma_{X;Y}(h) &= \text{Cov}(X_{t+h}, Y_t) \\ &= \text{Cov}(X_t, Y_{t-h}) \\ &= \text{Cov}(Y_{t-h}, X_t) \\ &= \gamma_{Y;X}(-h)\end{aligned}$$

Ta chứng minh được $\gamma_{X;Y}(h) = \gamma_{Y;X}(-h)$. Do đó, $\rho_{X;Y}(h) = \rho_{Y;X}(-h)$. □

Bài 4

Xét hai time series

$$X_t = W_t, \quad \text{và} \quad Y_t = W_t - \theta_1 W_{t-1} + U_t,$$

trong đó W_t và U_t là các white noise độc lập, với phương sai lần lượt là $\text{Var}(W_t) = \sigma_W^2$ và $\text{Var}(U_t) = \sigma_U^2$, còn θ_1 là hằng số nào đó.

- (a) Tính hàm ACF $\rho_Y(h)$ với $h = 0, \pm 1, \pm 2, \dots$ của time series Y_t , như hàm số theo các biến σ_W^2, σ_U^2 và θ .
- (b) Xác định hàm **cross-correlation** (CCF) $\rho_{X;Y}$ giữa X_t và Y_t .
- (c) Chứng tỏ X_t và Y_t là *jointly stationary*.

Giải

a) Hàm trung bình của Y_t

$$\mu_t = E(Y_t) = E(W_t - \theta W_{t-1} + U_t) = E(W_t) - \theta E(W_{t-1}) + E(U_t) = 0$$

$$\begin{aligned}\gamma_Y(h) &= \text{Cov}(Y_{t+h}, Y_t) \\ &= \text{Cov}(W_{t+h} - \theta W_{t+h-1} + U_{t+h}, W_t - \theta W_{t-1} + U_t) \\ &= \text{Cov}(W_{t+h}, W_t) - \theta \text{Cov}(W_{t+h}, W_{t-1}) + \text{Cov}(W_{t+h}, U_t) \\ &\quad - \theta \text{Cov}(W_{t+h-1}, W_t) + \theta^2 \text{Cov}(W_{t+h-1}, W_{t-1}) - \theta \text{Cov}(W_{t+h-1}, U_t) \\ &\quad + \text{Cov}(U_{t+h}, W_t) - \theta \text{Cov}(U_{t+h}, W_{t-1}) + \text{Cov}(U_{t+h}, U_t) \\ &= \text{Cov}(W_{t+h}, W_t) - \theta \text{Cov}(W_{t+h}, W_{t-1}) \\ &\quad - \theta \text{Cov}(W_{t+h-1}, W_t) + \theta^2 \text{Cov}(W_{t+h-1}, W_{t-1}) \\ &\quad + \text{Cov}(U_{t+h}, U_t)\end{aligned}$$

Với $h = 0$:

$$\begin{aligned}\gamma_Y(0) &= \text{Cov}(W_t, W_t) + \theta^2 \text{Cov}(W_{t-1}, W_{t-1}) + \text{Cov}(U_t, U_t) \\ &= (1 + \theta^2)\sigma_W^2 + \sigma_U^2\end{aligned}$$

Xét $h = 1$:

$$\gamma_Y(1) = -\theta \text{Cov}(W_t, W_t) = -\theta \sigma_W^2$$

Xét $h = -1$:

$$\gamma_Y(-1) = -\theta \text{Cov}(W_t, W_t) = -\theta \sigma_W^2$$

Xét $|h| \geq 2$:

$$\gamma_Y(h) = 0$$

Vậy hàm auto-covariance của time series Y_t là:

$$\gamma_Y(h) = \begin{cases} (1 + \theta^2)\sigma_W^2 + \sigma_U^2 & , h = 0 \\ -\theta \sigma_W^2 & , |h| = 1 \\ 0 & , |h| \geq 2 \end{cases}$$

Kết luận: Hàm ACF của time series Y_t

$$\rho_Y(h) = \frac{\gamma_Y(h)}{\gamma_Y(0)} = \begin{cases} 1 & , h = 0 \\ \frac{-\theta \sigma_W^2}{(1 + \theta^2)\sigma_W^2 + \sigma_U^2} & , |h| = 1 \\ 0 & , |h| \geq 2 \end{cases}$$

b)

Hàm cross-covariance giữa X_t và Y_t

$$\begin{aligned}\gamma_{X;Y}(h) &= \text{Cov}(X_{t+h}, Y_t) \\ &= \text{Cov}(W_{t+h}, W_t - \theta W_{t-1} + U_t) \\ &= \text{Cov}(W_{t+h}, W_t) - \theta \text{Cov}(W_{t+h}, W_{t-1}) + \text{Cov}(W_{t+h}, U_t) \\ &= \text{Cov}(W_{t+h}, W_t) - \theta \text{Cov}(W_{t+h}, W_{t-1})\end{aligned}$$

Xét $h = 0$

$$\gamma_{X;Y}(0) = \text{Cov}(W_t, W_t) = \sigma_W^2$$

Xét $h = -1$

$$\gamma_{X;Y}(-1) = -\theta \text{Cov}(W_{t-1}, W_{t-1}) = -\theta \sigma_W^2$$

Vậy hàm cross-covariance giữa X_t và Y_t

$$\gamma_{X;Y}(h) = \begin{cases} \sigma_W^2 & , h = 0 \\ -\theta\sigma_W^2 & , h = -1 \\ 0 & , \text{nơi khác} \end{cases}$$

Kết luận: Hàm auto-correlation giữa X_t và Y_t

$$\rho_{X;Y}(h) = \frac{\gamma_{X;Y}(h)}{\sqrt{\gamma_X(0)\gamma_Y(0)}} = \begin{cases} \frac{\sigma_W}{\sqrt{(1+\theta^2)\sigma_W^2 + \sigma_U^2}} & , h = 0 \\ \frac{-\theta\sigma_W}{\sqrt{(1+\theta^2)\sigma_W^2 + \sigma_U^2}} & , h = -1 \\ 0 & , \text{nơi khác} \end{cases}$$

c) $X_t = W_t$ là một White noise với $\text{Var}(X_t) = \text{Var}(W_t) = \sigma_W^2$ nên

$$\mathbb{E}(X_t) = 0 \quad \forall t \quad \text{và} \quad \gamma_X(h) = \begin{cases} \sigma_W^2 & , h = 0 \\ 0 & , h \neq 0 \end{cases}$$

Vậy X_t là một quá trình dừng.

Ta kiểm tra được X_t và Y_t là time series dừng và có hàm cross-covariance

$$\gamma_{X;Y}(h) = \begin{cases} \sigma_W^2 & , h = 0 \\ -\theta\sigma_W^2 & , h = -1 \\ 0 & , \text{nơi khác} \end{cases}$$

chỉ phụ thuộc vào h .

Kết luận: X_t và Y_t là dừng đồng thời (*jointly stationary*).

Bài 5

Cho W_t là một Gaussian white noise, $t = 0, \pm 1, \pm 2, \dots$, và xét

$$X_t = W_t W_{t-1} .$$

Xác định hàm trung bình (*mean function*) và hàm autocovariance của X_t . Kết luận xem X_t có phải quá trình dừng hay không.

Giải Giả thiết W_t là một Gaussian white noise, nên:

$$\begin{cases} W_t, W_{t-1} \text{ độc lập} \\ \mathbb{E}(W_t) = 0 \\ \mathbb{E}(W_{t-1}) = 0 \end{cases}$$

Hàm trung bình của X_t

$$\mu_t = \mathbb{E}(X_t) = \mathbb{E}(W_t W_{t-1}) = \mathbb{E}(W_t) \mathbb{E}(W_{t-1}) = 0$$

Nhận xét: Hàm trung bình không phụ thuộc vào t . (1)

Hàm auto-covariance của X_t

$$\begin{aligned} \gamma_X(h) &= (X_{t+h}, X_t) \\ &= \mathbb{E}[(X_{t+h} - \mathbb{E}(X_{t+h}))(X_t - \mathbb{E}(X_t))] \\ &= \mathbb{E}(X_{t+h} X_t) \end{aligned}$$

Với $h = 0$, ta được:

$$\begin{aligned} \gamma_X(h) &= \mathbb{E}(X_t X_t) = \mathbb{E}(X_t^2) \\ &= \mathbb{E}(W_t^2 W_{t-1}^2) \\ &= \mathbb{E}(W_t^2) \mathbb{E}(W_{t-1}^2) \\ &= [(W_t) + \mathbb{E}(W_t)^2][(W_{t-1}) + \mathbb{E}(W_{t-1})^2] \\ &= (W_t)(W_{t-1}) \\ &= \sigma_W^4 \end{aligned}$$

Với $h = 1$, ta được:

$$\gamma_X(h) = \mathbb{E}(X_{t+1} X_t) = \mathbb{E}(W_{t+1} W_t W_t W_{t-1}) = \mathbb{E}(W_{t+1}) \mathbb{E}(W_t^2) \mathbb{E}(W_{t-1}) = 0$$

Với $|h| > 1$, ta được:

$$\gamma_X(h) = \mathbb{E}(X_{t+h} X_t) = \mathbb{E}(W_{t+h} W_{t+h-1} W_t W_{t-1}) = \mathbb{E}(W_{t+h}) \mathbb{E}(W_{t+h-1}) \mathbb{E}(W_t) \mathbb{E}(W_{t-1}) = 0$$

Hàm auto-covariance của X_t

$$\gamma_X(h) = \begin{cases} \sigma_W^4 & , h = 0 \\ 0 & , |h| \geq 1 \end{cases}$$

Nhận xét: Hàm auto-covariance của X_t chỉ phụ thuộc vào khoảng cách h . (2)

Kết luận: Từ (1) và (2), ta kết luận X_t là một quá trình dừng. □

ARMA and ARIMA models

Bài 6

Hãy xác định các mô hình **ARMA** (p, q) sau (lưu ý về vấn đề dư thừa tham số cần thiết (*parameter redundancy*) trong mô hình **ARMA**), và xác định xem mỗi quá trình **ARMA** này có thỏa tính chất *causal* và/hoặc *invertible* hay không:

(a) $X_t = 0.80X_{t-1} - 0.15X_{t-2} + W_t - 0.30W_{t-1}$.

(b) $X_t = X_{t-1} - 0.50X_{t-2} + W_t - W_{t-1}$.

Giải

a)

$$\begin{aligned} X_t &= 0.80X_{t-1} - 0.15X_{t-2} + W_t - 0.30W_{t-1} \\ \Leftrightarrow X_t - 0.80X_{t-1} + 0.15X_{t-2} &= W_t - 0.30W_{t-1} \end{aligned}$$

Nhận định sơ bộ: Mô hình ở câu a có dạng mô hình ARMA(2, 1).

$$\begin{aligned} X_t &= 0.80X_{t-1} - 0.15X_{t-2} + W_t - 0.30W_{t-1} \\ \Leftrightarrow (1 - 0.80B + 0.15B^2)X_t &= (1 - 0.30B)W_t \end{aligned}$$

Từ công thức trên, ta có:

$$\begin{cases} \phi(B) = 1 - 0.80B + 0.15B^2 \\ \theta(B) = 1 - 0.30B \end{cases} \quad \text{và} \quad \begin{cases} \phi(z) = 1 - 0.8z + 0.15z^2 \\ \theta(z) = 1 - 0.30z \end{cases}$$

Vấn đề 3 (Sự dư thừa tham số): $\phi(z)$ và $\theta(z)$ không có nhân tử chung.

Ta có:

$$\phi(z) = (1 - 0.30z)(1 - 0.50z) \quad \text{và} \quad \theta(z) = 1 - 0.30z$$

Sau khi rút gọn nhân tử chung, ta được:

$$\phi(z) = 1 - 0.50z \quad \text{và} \quad \theta(z) = 1$$

Vấn đề 1 (Tính Causality):

Ta sử dụng mệnh đề:

$$\begin{aligned} &\text{ARMA } (p, q) \text{ model } X_t \text{ là causal} \\ \Leftrightarrow &\phi(z) \neq 0, \quad \forall |z| \leq 1 \\ \Leftrightarrow &\text{Nếu } z_0 \text{ là nghiệm của } \phi(z_0) = 0 \text{ thì } |z_0| > 1 \end{aligned}$$

Ta có:

$$\phi(z_0) = 1 - 0.50z_0 = 0$$

Giải được nghiệm của $\phi(z_0)$ là $z_0 = 2$. Tức là $|z_0| = 2 > 1$.

Như vậy, mô hình trên là **Causal**.

Vấn đề 2 (Tính invertibility):

Ta sử dụng mệnh đề:

$$\begin{aligned} & \text{ARMA } (p, q) \text{ model } X_t \text{ là invertible} \\ \Leftrightarrow & \theta(z) \neq 0, \quad \forall |z| \leq 1 \end{aligned}$$

Ta có:

$$\theta(z) = 1 \neq 0$$

Như vậy, $\forall |z| \leq 1$ ta luôn có $\theta(z) \neq 0$.

Như vậy, mô hình trên là **Invertible**.

Ta thu được mô hình:

$$\begin{aligned} (1 - 0.50B)X_t &= W_t \\ \Rightarrow X_t - 0.50X_{t-1} &= W_t \end{aligned}$$

Kết luận: Mô hình ở câu a là mô hình AR(1).

b)

$$\begin{aligned} X_t &= X_{t-1} - 0.5X_{t-2} + W_t - W_{t-1} \\ \Leftrightarrow X_t - X_{t-1} + 0.5X_{t-2} &= W_t - W_{t-1} \end{aligned}$$

Nhận định sơ bộ: Mô hình ở câu b có dạng mô hình ARMA(2, 1).

$$\begin{aligned} X_t &= X_{t-1} - 0.5X_{t-2} + W_t - W_{t-1} \\ \Leftrightarrow X_t - X_{t-1} + 0.5X_{t-2} &= W_t - W_{t-1} \\ \Leftrightarrow (1 - B + 0.5B^2)X_t &= (1 - B)W_t \end{aligned}$$

Từ công thức trên, ta có:

$$\begin{cases} \phi(B) = 1 - B + 0.5B^2 \\ \theta(B) = 1 - B \end{cases} \quad \text{và} \quad \begin{cases} \phi(z) = 1 - z + 0.5z^2 \\ \theta(z) = 1 - z \end{cases}$$

Vấn đề 3 (Sự dư thừa tham số): $\phi(z)$ và $\theta(z)$ không có nhân tử chung.

Ta thấy $\phi(z)$ và $\theta(z)$ không có nhân tử chung nên:

$$\phi(z) = 1 - z + 0.5z^2 \quad \text{và} \quad \theta(z) = 1 - z$$

Vấn đề 1 (Tính Causality):

Ta sử dụng mệnh đề:

ARMA (p, q) model X_t là causal

$$\Leftrightarrow \phi(z) \neq 0, \quad \forall |z| \leq 1$$

$$\Leftrightarrow \text{Nếu } z_0 \text{ là nghiệm của } \phi(z_0) = 0 \text{ thì } |z_0| > 1$$

Ta xét:

$$\phi(z_0) = 1 - z_0 + 0.5z_0^2 = 0$$

Giải được nghiệm của $\phi(z_0)$ là $z_0 = 1 \pm i$.

Do đó $|z_0| = \sqrt{1^2 + 1^2} = \sqrt{2} > 1$.

Như vậy, mô hình trên là **Causal**.

Vấn đề 2 (Tính invertibility):

Ta sử dụng mệnh đề:

ARMA (p, q) model X_t là invertible

$$\Leftrightarrow \theta(z) \neq 0, \quad \forall |z| \leq 1$$

Ta xét:

$$\theta(z) = 1 - 0.5z_0 = 0$$

Giải được nghiệm của $\theta(z_0)$ là $z_0 = 2$. Do đó $|z_0| = 2 > 1$.

Như vậy, mô hình trên là **Invertible**.

Ta thu được mô hình:

$$(1 - B + 0.5B^2)X_t = (1 - B)W_t$$

Kết luận: Mô hình ở câu b là mô hình ARMA(2, 1).

IV Bài tập thực hành

Bài thực hành 1

1. Tiền xử lý và thống kê mô tả.
2. Đánh giá phân phối và biến đổi Logarithm.
3. Tương quan và biểu đồ Boxplot.
4. Xây dựng và kiểm định mô hình ($M1.1$ & $M1.2$).
5. Lựa chọn mô hình và dự báo.

Mô tả dữ liệu

Mục tiêu của bài toán là xây dựng mô hình hồi quy tuyến tính bội để phân tích các yếu tố ảnh hưởng đến chi phí hoạt động (*nonclaim expenses*) của các công ty bảo hiểm tại Mỹ.

Dữ liệu

- **File:** Insurance-company-expenses.csv
- **Số quan sát:** 384 công ty bảo hiểm

Biến phụ thuộc (Y)

- **EXPENSES:** Tổng chi phí không liên quan đến bồi thường (triệu USD).

Biến giải thích (X)

X_1 : **GROUP:** Indicates whether the company is affiliated (0/1).

X_2 : **MUTUAL:** Indicates whether the company is a mutual company (0/1).

X_3 : **STOCK:** Indicates whether the company is a stock company (0/1).

X_4 : **STAFFWAGE:** (BLS variable) Annual average wage of the insurer's administrative staff (in thousands of dollars).

X_5 : **AGENTWAGE:** (BLS variable) Annual average wage of the insurance agent (in thousands of dollars).

X_6 : **LONGLOSS:** Losses incurred for long tail lines (in millions of dollars).

X_7 : **SHORTLOSS:** Losses incurred for short tail lines (in millions of dollars).

X_8 : **GPWPERSONAL:** Gross premium written for personal lines (in millions of dollars).

X_9 : **GPWCOMM:** Gross premium written for commercial lines (in millions of dollars).

X_{10} : **ASSETS:** Net admitted assets (in millions of dollars).

X_{11} : **CASH:** Cash and invested assets (in millions of dollars).

Phân tích mã nguồn

```
# Đọc dữ liệu
data <- read.csv("D:/Insurance-company-expenses.csv")

#1.1.1. Tiền xử lý dữ liệu
# Loại bỏ các dòng có giá trị Missing (NA)
data <- na.omit(data)

# Xử lý các giá trị quan trắc < 0 cho các biến không cho phép âm
data <- data[data$EXPENSES >= 0 & data$ASSETS >= 0 & data$LONGLOSS >= 0 & data$GPWPERSONAL
  >= 0 & data$GPWCOMM >= 0, ]

#1.1.2. Summary statistics cho các biến non-binary
non_binary_vars <- c("EXPENSES", "STAFFWAGE", "AGENTWAGE", "LONGLOSS",
  "SHORTLOSS", "GPWPERSONAL", "GPWCOMM", "ASSETS", "CASH")
summary_stats <- summary(data[, non_binary_vars])
print(summary_stats)
```

```
##      EXPENSES      STAFFWAGE      AGENTWAGE      LONGLOSS
## Min.   :0.0000277 Min.   : 51.73 Min.   : 47.47 Min.   :0.0000000
## 1st Qu.:0.0016978 1st Qu.: 80.06 1st Qu.: 74.55 1st Qu.:0.0000457
## Median :0.0090993 Median : 84.36 Median : 78.65 Median :0.0025903
## Mean   :0.0454466 Mean   : 87.15 Mean   : 80.06 Mean   :0.0265851
## 3rd Qu.:0.0301485 3rd Qu.: 93.82 3rd Qu.: 85.30 3rd Qu.:0.0127857
## Max.   :1.2369463 Max.   :137.48 Max.   :126.17 Max.   :0.8539152

##      SHORTLOSS      GPWPERSONAL      GPWCOMM      ASSETS
## Min.   :-0.0029507 Min.   :0.000000 Min.   :0.000000 Min.   :0.000321
## 1st Qu.: 0.0002764 1st Qu.:0.000000 1st Qu.:0.003905 1st Qu.:0.012295
## Median : 0.0044698 Median :0.001130 Median :0.026219 Median :0.056746
## Mean   : 0.0375858 Mean   :0.05783 Mean   :0.123403 Mean   :0.338073
## 3rd Qu.: 0.0224038 3rd Qu.:0.03267 3rd Qu.:0.087702 3rd Qu.:0.188796
## Max.   : 1.1710587 Max.   :1.82249 Max.   :4.189401 Max.   :8.705380

##      CASH
## Min.   :0.000018
## 1st Qu.:0.011194
## Median :0.049362
## Mean   :0.315516
## 3rd Qu.:0.178365
## Max.   :8.823477
```

summary: non binary vars


Nhận xét:

- Các giá trị bị thiếu (NA) được loại bỏ nhằm tránh lỗi trong quá trình tính toán.
- Các biến *EXPENSES* (Chi phí), *ASSETS* (Tài sản) và *GPWCOMM* (Phí bảo hiểm gộp) đại diện cho quy mô hoạt động, do đó các biến này không thể âm.

- Việc tính toán Trung bình (Mean) và Trung vị (Median) giúp xác định mức độ lệch của dữ liệu.
- Các biến *GROUP*, *MUTUAL* và *STOCK* là các biến định danh (Binary), chỉ đóng vai trò phân loại nhóm, do đó không thực hiện các phép biến đổi logarithm hay các thống kê giả định phân phối chuẩn.


```
#1.2 histogram and Q-Q normal plot
```

```
hist(data$EXPENSES, main="Histogram of EXPENSES", col="skyblue", xlab="Expenses")
```



```
qqnorm(data$EXPENSES, main="Q-Q Plot of EXPENSES")
```


```
qqline(data$EXPENSES)
```




Nhận xét về biến *EXPENSES* (trước biến đổi):

- Biểu đồ Histogram của biến *EXPENSES* cho thấy phân phối lệch phải nặng nề. Nếu đưa trực tiếp biến *EXPENSES* vào mô hình hồi quy mà không thực hiện biến đổi, các giá trị cực lớn này sẽ kéo mô hình bị lệch, dẫn đến việc ước lượng các hệ số không còn chính xác và vi phạm giả định về phân phối chuẩn của sai số.

```
# 1.2 Biến đổi logarithm ln(Y) , sau đó đánh giá
data$LNEXPENSES_raw <- log(data$EXPENSES)
hist(data$LNEXPENSES_raw, main="Histogram of ln(EXPENSES)", col="lightgreen", xlab="ln(Expenses)")
```



```
qqnorm(data$LNEXPENSES_raw, main="Q-Q Plot of ln(EXPENSES)")
qqline(data$LNEXPENSES_raw)
```



Nhận xét:

- *Sự thay đổi:* Sau khi thực hiện phép biến đổi Logarithm, biểu đồ Histogram trở nên cân đối hơn. Các điểm trên Q-Q plot bám sát đường thẳng hơn so với dữ liệu gốc.

Kết luận: Phép biến đổi Logarithm đã giúp đưa dữ liệu về trạng thái gần với phân phối chuẩn. Điều này cho phép thực hiện các kiểm định thống kê như kiểm định t và kiểm định F một cách hợp lệ và đáng tin cậy hơn trong các bước phân tích tiếp theo.


```
#1.3 Biến đổi ln(1+u) cho tất cả các biến non-binary theo yêu cầu
data$LNEXPENSES <- log(1 + data$EXPENSES)
data$LNSTAFFWAGE <- log(1 + data$STAFFWAGE)
data$LNAGENTWAGE <- log(1 + data$AGENTWAGE)
data$LNLONGLOSS <- log(1 + data$LONGLOSS)
data$LNSHORTLOSS <- log(1 + data$SHORTLOSS)
data$LNBPWPERSONAL <- log(1 + data$BPWPERSONAL)
data$LNBPWCOMM <- log(1 + data$BPWCOMM)
data$LNASSETS <- log(1 + data$ASSETS)
data$LNCASH <- log(1 + data$CASH)
##
# Tạo bảng tương quan cho các biến đã biến đổi
Log_vars <- c("LNEXPENSES", "LNSTAFFWAGE", "LNAGENTWAGE", "LNLONGLOSS", "LNSHORTLOSS", "
             LNBPWPERSONAL", "LNBPWCOMM", "LNASSETS", "LNCASH")
cor_matrix <- cor(data[, Log_vars])
print(cor_matrix["LNEXPENSES", ]) # Xem tương quan với LNEXPENSES
```

##	LNEXPENSES	LNSTAFFWAGE	LNAGENTWAGE	LNLONGLOSS	LNSHORTLOSS
##	1.00000000	0.10224894	0.08589049	0.91832877	0.92989619
##	LNGPWPERSOAL	LNGPWCOMM	LNASSETS	LNCASH	
##	0.81634805	0.86716951	0.86280884	0.86019300	

Table of correlations

Ba biến giải thích có mức độ tương quan cao nhất với biến *LNEXPENSES* bao gồm *LNSHORTLOSS*, *LNLONGLOSS* và *LNASSETS*.

```
#Boxplot cho LNEXPENSES theo GROUP
boxplot(LNEXPENSES ~ GROUP, data = data,
        main="LNEXPENSES by GROUP",
        xlab="Group (0: No, 1: Affiliated)",
        ylab="LNEXPENSES", col=c("orange", "cyan"))
```



Nhận xét từ biểu đồ Boxplot:

- *Về mức độ tập trung:* Quan sát biểu đồ cho thấy đường gạch ngang (Median) của *GROUP 1* nằm cao hơn rõ rệt so với *GROUP 0*. Điều này cho thấy rằng đa số các công ty thuộc tập đoàn có mức chi phí vận hành cao hơn so với các công ty hoạt động độc lập.
- *Về dải biến thiên:* Nhóm *GROUP 1* có dải giá trị rộng hơn và hộp dài hơn, cho thấy sự khác biệt về quy mô chi phí giữa các công ty trong cùng tập đoàn là tương đối lớn.
- *Về giá trị ngoại lai (Outliers):* Các điểm chấm nằm xa khỏi hộp biểu hiện những công ty có mức chi phí đột biến so với mặt bằng chung của nhóm tương ứng.

Kết luận: Nhóm công ty thuộc tập đoàn (*GROUP 1*) có tổng chi phí cao hơn. Các công ty trong nhóm *GROUP 1* thường sở hữu quy mô tài sản lớn hơn và chịu mức tổn thất cao hơn, từ đó dẫn đến chi phí quản lý và nghiệp vụ cao hơn.

```
# Xây dựng mô hình hồi quy tuyến tính (M1.1) cho LNEXPENSES
m1.1 <- lm(LNEXPENSES ~ GROUP + MUTUAL + STOCK + LNSTAFFWAGE + LNAGENTWAGE + LNLONGLOSS +
          LNSHORTLOSS + LNGPWPERSOAL + LNGPWCOMM + LNASSETS + LNCASH, data = data)
summary(m1.1)
```

```
##
## Call:
## lm(formula = LNEXPENSES ~ GROUP + MUTUAL + STOCK + LNSTAFFWAGE +
##      LNAGENTWAGE + LNLONGLOSS + LNSHORTLOSS + LNGPWPERSOAL +
##      LNGPWCOMM + LNASSETS + LNCASH, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.132488 -0.003141 -0.000270  0.002414  0.124092
##

## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -5.870e-03  4.569e-02  -0.128  0.897850
## GROUP         4.744e-05  2.828e-03   0.017  0.986626
## MUTUAL       -1.938e-03  4.293e-03  -0.451  0.651936
## STOCK        -3.683e-03  3.837e-03  -0.960  0.337777
## LNSTAFFWAGE   1.817e-03  1.442e-02   0.126  0.899813
## LNAGENTWAGE   1.634e-04  1.663e-02   0.010  0.992165
## LNLONGLOSS    4.452e-01  4.587e-02   9.706 < 2e-16 ***
## LNSHORTLOSS   3.015e-01  3.270e-02   9.221 < 2e-16 ***
## LNGPWPERSOAL  7.095e-02  1.992e-02   3.562 0.000419 ***
## LNGPWCOMM     8.741e-02  1.717e-02   5.091 5.82e-07 ***
## LNASSETS     -5.444e-02  4.740e-02  -1.149 0.251500
## LNCASH        9.618e-02  4.674e-02   2.058 0.040358 *

## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.02229 on 350 degrees of freedom
## Multiple R-squared:  0.9429, Adjusted R-squared:  0.9411
## F-statistic: 525.5 on 11 and 350 DF, p-value: < 2.2e-16
```

Đánh giá tổng quát mô hình M1.1:

- *Độ phù hợp của mô hình:* Mô hình có hệ số R^2 hiệu chỉnh đạt 0.9501, cho thấy hơn 95% sự biến động của chi phí được giải thích bởi các biến trong mô hình.

- *Ý nghĩa thống kê của các biến:* Các biến liên quan đến tổn thất bảo hiểm (*LNLONGLOSS*, *LNSHORTLOSS*) và phí bảo hiểm thương mại (*LNGPWCOMM*) có tác động mạnh và đều có ý nghĩa thống kê cao ($p < 0.01$).
- **F-statistic ($p\text{-value} < 2.2 \times 10^{-16}$):** Giá trị này cho thấy mô hình có **ý nghĩa thống kê tổng thể rất cao**, tức là tập hợp các biến giải thích trong mô hình có khả năng giải thích biến phụ thuộc *LNEXPENSES* một cách đáng kể.
- **Dấu hiệu bất thường của biến *LNASSETS*:** Biến *LNASSETS* có hệ số ước lượng mang dấu âm (Estimate = -0.0959), trái với kỳ vọng kinh tế. Về mặt lý thuyết, khi quy mô tài sản tăng thì chi phí hoạt động của doanh nghiệp bảo hiểm thường có xu hướng tăng, do đó hệ số kỳ vọng phải mang dấu dương.

Việc hệ số của *LNASSETS* bị âm và có giá trị p -value thấp hơn ngưỡng 0.05 là dấu hiệu điển hình của hiện tượng **đa cộng tuyến**, cụ thể là sự xung đột thông tin giữa biến *LNASSETS* và biến *LNCASH* (với $p = 0.005$). Hiện tượng này làm cho các ước lượng hệ số trở nên kém ổn định và không phản ánh đúng bản chất kinh tế của mối quan hệ.

```
m1.2 <- lm(LNEXPENSES ~ GROUP + LNSTAFFWAGE + LNAGENTWAGE +
           LNLONGLOSS + LNSHORTLOSS + LNGPWPERSONAL + LNGPWCOMM + LNASSETS,
           data = data)
summary(m1.2)
```

```
##
## Call:
## lm(formula = LNEXPENSES ~ GROUP + LNSTAFFWAGE + LNAGENTWAGE +
##      LNLONGLOSS + LNSHORTLOSS + LNGPWPERSONAL + LNGPWCOMM + LNASSETS,
##      data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.134802 -0.002658 -0.000215  0.002202  0.127735
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -0.011210   0.045649  -0.246  0.806150
## GROUP        -0.001416   0.002620  -0.540  0.589321
## LNSTAFFWAGE    0.003924   0.014370   0.273  0.784981
## LNAGENTWAGE  -0.001263   0.016599  -0.076  0.939388
## LNLONGLOSS    0.445726   0.045532   9.789 < 2e-16 ***
## LNSHORTLOSS   0.305838   0.032640   9.370 < 2e-16 ***
## LNGPWPERSONAL 0.072535   0.019776   3.668 0.000282 ***
## LNGPWCOMM     0.076053   0.016387   4.641 4.89e-06 ***
## LNASSETS      0.042081   0.007432   5.662 3.10e-08 ***
```



```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.02237 on 353 degrees of freedom
## Multiple R-squared:  0.942, Adjusted R-squared:  0.9407
## F-statistic: 716.9 on 8 and 353 DF, p-value: < 2.2e-16
```

Nhận xét từ bảng Coefficients:

- *Độ phù hợp của mô hình:* Hệ số R^2 hiệu chỉnh (Adjusted R^2) đạt 0.9407, cho thấy các biến giải thích trong mô hình có thể giải thích được gần 95% sự biến động của chi phí *LNEXPENSES*. Điều này cho thấy mô hình có mức độ phù hợp rất cao.
- *Các biến có ý nghĩa thống kê ($p\text{-value} < 0.05$):* Bao gồm *LNLONGLOSS*, *LNSHORTLOSS*, *LNGPWCOMM* và *LNASSETS*. Các biến này đều có mức ý nghĩa rất cao, được ký hiệu bởi dấu sao *** trong bảng kết quả.
- *Các biến không có ý nghĩa thống kê ($p\text{-value} > 0.05$):* Bao gồm *GROUP*, *LNSTAFFWAGE*, *LNAGENTWAGE* và *LNGPWPERSONAL*.

```
# Lấy giá trị trung vị của biến gốc
median_expenses <- median(data$EXPENSES)
median_gpwcomm <- median(data$GPWCOMM)

# Tính toán mức tăng tuyệt đối khi GPWCOMM tăng 1 đôla
delta_expenses <- 0.0977806 * (median_expenses / median_gpwcomm)
cat("Khi GPWCOMM tăng 1$, EXPENSES tăng khoảng:", delta_expenses, "$")
##Khi GPWCOMM tăng 1$, EXPENSES tăng khoảng: 0.03393446 $
```

Kết luận: Khi *GPWCOMM* tăng 1%, chi phí *EXPENSES* tăng trung bình khoảng 0.0339%, trong điều kiện các yếu tố khác không đổi.

```
#1.5
## 1. So sánh R-squared hiệu chỉnh (Adjusted R-squared)
summary(m1.1)$adj.r.squared
##[1] 0.950126
```

```
summary(m1.2)$adj.r.squared
##[1] 0.9491969
```

```
# 2. So sánh chỉ số AIC
AIC(m1.1)
##[1] -1674.527
AIC(m1.2)
##[1] -1671.084
```

```
# 3. Kiểm định ANOVA để xem việc loại bỏ 3 biến có làm mô hình tệ đi đáng kể không
anova(m1.2, m1.1)
```

Phân tích kết quả ANOVA:

- *Mục tiêu:* So sánh mô hình tinh gọn ($M1.2$ với 8 biến) và mô hình đầy đủ ($M1.1$ với 11 biến).
- *Chỉ số F -test:* Kết quả kiểm định cho thấy giá trị $Pr(> F) = 0.02764$.
- *Kết luận thống kê:* Do p -value = 0.02764 < 0.05. Điều này cho thấy mô hình đầy đủ có khả năng giải thích tốt hơn một chút, nhưng sự khác biệt này là không đáng kể so với lợi ích về tính tinh gọn và sự ổn định của hệ số hồi quy.

Lý do lựa chọn mô hình Mex1 (M1.2):

- *Hiệu quả cao:* Hệ số R^2_{adj} đạt 0.9407, gần như không thay đổi so với mô hình đầy đủ (0.9501), mặc dù số lượng biến giải thích ít hơn.
- Mô hình khắc phục được hiện tượng đa cộng tuyến giữa $ASSETS$ và $CASH$, giúp hệ số của biến $LNASSETS$ trở nên ổn định và phù hợp với kỳ vọng kinh tế.

```
mex1 <- m1.2

new_data <- data.frame(
  GROUP = 1,
  LNSTAFFWAGE = log(1 + median(data$STAFFWAGE)),
  LNAGENTWAGE = log(1 + median(data$AGENTWAGE)),
  LNLONGLOSS = log(1 + 0.025),
  LNSHORTLOSS = log(1 + 0.040),
  LNGPWPERSONAL = log(1 + 0.050),
  LNGPWCOMM = log(1 + 0.120),
  LNASSETS = log(1 + 0.400)
)

# Dự báo giá trị log
conf_log <- predict(mex1, newdata = new_data, interval = "confidence", level = 0.95)
pred_log <- predict(mex1, newdata = new_data, interval = "prediction", level = 0.95)
print(conf_log)
```

```
##               fit               lwr               upr
## 1 0.04872021 0.04519132 0.05224909
```

```
print(pred_log)
```

```
##           fit           lwr           upr
## 1 0.04872021 0.007278585 0.09016183
```

```
# Chuyển đổi ngược về EXPENSES = exp(LNEXPENSES) - 1
conf_real <- exp(conf_log) - 1
print(conf_real)
```

```
##           fit           lwr           upr
## 1 0.04992655 0.04622801 0.05363816
```

Khoảng tin cậy 95 cho giá trị dự báo

```
pred_real <- exp(pred_log) - 1
print(pred_real)
```

```
##           fit           lwr           upr
## 1 0.04992655 0.007305138 0.09435137
```

Giá trị dự báo EXPENSES

Nhận xét kết quả dự báo:

- *Giá trị dự báo:* Với kịch bản tăng trưởng giả định, chi phí hoạt động dự kiến đạt khoảng 0.0499.
- *Độ tin cậy của ước lượng:* Khoảng tin cậy 95% nằm trong khoảng (0.0462; 0.0536), tương đối hẹp, cho thấy sai số ước lượng thấp và mô hình có độ chính xác cao.
- *Biến động dự báo:* Khoảng dự báo (0.0073; 0.0944) rộng hơn do đã tính đến sai số ngẫu nhiên giữa các doanh nghiệp cụ thể, phản ánh sự không chắc chắn vốn có trong dự báo chi phí ở cấp độ cá thể.

Bài thực hành 2

1. Sử dụng dữ liệu giai đoạn 01/01/2015 – 31/12/2018 làm training dataset để xây dựng mô hình ARIMA hoặc SARIMA dự báo nhu cầu điện.
2. Thể hiện time series data và predicted values (dựa trên mô hình xây dựng được) trên cùng một time plot
3. Sử dụng mô hình đã xây dựng để dự báo nhu cầu điện giai đoạn 01/01/2019 – 31/12/2019.
4. So sánh giá trị dự báo với dữ liệu thực tế (testing dataset) giai đoạn 01/01/2019 - 31/12/2019 tính sai số dự báo, đồng thời thể hiện testing data so với predicted values trên cùng time plot.
5. Nhận xét xem các giá trị dự báo mà mô hình đưa ra có phù hợp với dữ liệu hay không.

1.MÔ TẢ DỮ LIỆU

Dữ liệu bao gồm biến chính là nhu cầu điện hằng ngày (demand, MWh) cùng các biến liên quan đến thời tiết (nhiệt độ, bức xạ mặt trời, lượng mưa) và yếu tố lịch sinh hoạt (ngày học, ngày lễ), được sử dụng để phân tích và dự báo nhu cầu điện.

2.DỮ LIỆU

- **File:** electric-demand-australia.csv
- **Số quan sát:** 2106 ngày

Các biến trong dataset

- **demand:** tổng nhu cầu sử dụng điện mỗi ngày (MWh)
- **min_temperature:** nhiệt độ thấp nhất trong ngày (°C)
- **max_temperature:** nhiệt độ cao nhất trong ngày (°C)
- **solar_exposure:** tổng năng lượng mặt trời trong ngày (MJ/m²)
- **rainfall:** lượng mưa trung bình ngày (mm)
- **school_day:** Số ngày đi học
- **holiday:** Số ngày nghỉ lễ

Chia tệp dữ liệu

- **Training set:** 01/01/2015 - 31/12/2018
- **Testing set:** 01/01/2019 - 31/12/2019

3.PHÂN TÍCH MÃ NGUỒN

Nạp và xử lý dữ liệu

```

edata <- read.csv("D:/download/electric-demand-australia.csv")
edata$school_day <- as.numeric(ifelse(edata$school_day == "Y", 1, 0))
edata$holiday <- as.numeric(ifelse(edata$holiday == "Y", 1, 0))
edata$min_temperature <- as.numeric(as.character(edata$min_temperature))
edata$max_temperature <- as.numeric(as.character(edata$max_temperature))
edata$solar_exposure <- as.numeric(as.character(edata$solar_exposure))
edata$rainfall <- as.numeric(as.character(edata$rainfall))
edata$date <- as.Date(edata$date)
edata <- edata[order(edata$date), ]
edata <- na.omit(edata)
train <- edata[edata$date >= as.Date("2015-01-01") & edata$date <= as.Date("2018-12-31"), ]
test <- edata[edata$date >= as.Date("2019-01-01") & edata$date <= as.Date("2019-12-31"), ]

```


- **Chuẩn hóa (Casting):** Chuyển đổi các biến phân loại (school_day, holiday) và biến số (temperature, solar_exposure, rainfall) về dạng dữ liệu số thực để tính toán.
- **Định dạng thời gian:** Chuyển cột date sang kiểu dữ liệu ngày tháng và sắp xếp theo thứ tự tăng dần.
- **Làm sạch (Cleaning):** Loại bỏ các giá trị thiếu (NA) để đảm bảo mô hình không bị lỗi.
- **Phân tách (Splitting):** Chia dữ liệu thành tập **Train** (2015–2018) để huấn luyện mô hình và tập **Test** (2019) để đánh giá độ chính xác dự báo.

Trực quan hóa dữ liệu từ năm 2015 tới 2018

```

demand_ts_7<-ts(train$demand, frequency = 7)
plot.ts (demand_ts_7, xlab= "Số Tuần")



```



Kiểm tra mùa vụ

```
library(forecast)
library(ggplot2)
demand_ts <- ts(train$demand, frequency = 365, start = c(2015, 1))
demand_ts_fixed <- window(demand_ts, end = c(2018, 365))
ggseasonplot(demand_ts_fixed,
             year.labels = TRUE,
             main = "Bieu do so sanh gia tri tung ngay trong nam",
             xlab = "Ngay trong nam",
             ylab = "Demand") +
  theme_minimal() +
  theme(legend.position = "right") +
  guides(colour = guide_legend(title = "Nam"))
demand_30days <- subset(demand_ts, start = 1, end = 30)

data_sub <- train[1:30, ]
plot(data_sub$date, data_sub$demand,
     type = "b",
     main = "Nhu cau dien 30 ngay dau nam 2015",
     xlab = "Ngay",
     ylab = "Demand (MWh)")
```



- **Nhận xét:** 2 đồ thị cho thấy hình dạng biến động nhu cầu điện tương tự qua các năm, với các đỉnh và đáy nhỏ xuất hiện mỗi 7 ngày xác nhận sự tồn tại của yếu tố mùa vụ .

Kiểm tra tính xu hướng

```
library(trend)
mk_test <- mk.test(demand_ts)
print(mk_test)
```

```

Mann-Kendall trend test

data: demand_ts
z = -7.4163, n = 1457, p-value = 1.205e-13
alternative hypothesis: true S is not equal to 0
sample estimates:
            S            varS            tau
-1.375560e+05  3.440191e+08 -1.296847e-01

```

- **Nhận xét:** Nhận thấy vì $p_value < 0.05$ nên chuỗi demand có tính xu hướng

Sai phân loại bỏ các yếu tố gây xu hướng và mùa vụ

```

demand_ts_7 <- ts(train$demand, frequency = 7)
lx <- log(demand_ts_7)
dlx <- diff(lx)
ddlx <- diff(dlx, 7)


par(
  mfrow = c(1, 2),
  mar = c(4, 4.5, 3, 1)
)

plot.ts(dlx,
  main = "Loại bỏ xu hướng\n(Sai phân bậc 1)",
  xlab = "Thời gian (tuần)",
  ylab = expression(Delta*log(Demand)))

plot.ts(ddlx,
  main = "Loại bỏ xu hướng và mùa vụ\n(Sai phân bậc 1 + chu kỳ 7)",
  xlab = "Thời gian (tuần)",
  ylab = expression(Delta[7]*Delta*log(Demand)))

par(mfrow = c(1, 1))

```



- **Nhận xét:** Sau khi thực hiện sai phân bậc 1 và sai phân mùa vụ chu kỳ 7, chuỗi nhu cầu điện đã loại bỏ được cả xu hướng và yếu tố mùa vụ theo tuần nhưng vẫn còn các đỉnh nhọn khá lớn ở đầu năm mới

Kiểm tra tính dừng sau khi đã sai phân

```
library(tseries)
adf.test(ddlx)
```


```
Warning: p-value smaller than printed p-value
Augmented Dickey-Fuller Test

data: ddx
Dickey-Fuller = -17.614, Lag order = 11, p-value = 0.01
alternative hypothesis: stationary
```

- **Nhận xét:** Nhận thấy $p_value < 0.01$ nên chuỗi đã dừng từ đó ta đi vào phân tích mô hình SARIMA

Xây dựng ACF và PACF

```
library(astsa)
acf2(ddlx)
```

Nhận xét ACF và PACF sau sai phân

- **Thành phần mùa vụ** Quan sát hàm tự tương quan (ACF) cho thấy tại độ trễ $lag = 7$ xuất hiện sự suy giảm đột ngột, trong khi các độ trễ bội của 7 không còn tương quan đáng kể. Hàm tự tương quan riêng phần (PACF) thể hiện các giá trị tại $lag = 14, 21$ giảm dần từ từ về 0. Điều này cho thấy thành phần mùa vụ có dạng trung bình trượt mùa vụ, do đó lựa chọn $P = 0$ và $Q = 1$ là phù hợp.
- **Thành phần phi mùa vụ** Đối với thành phần phi mùa vụ, cả ACF và PACF đều xấp xỉ 0 tại $lag = 1$, cho thấy không tồn tại tương quan đáng kể ở độ trễ bậc 1. ACF giảm xuống khoảng -0.15 tại $lag = 3$ rồi nhanh chóng trở về gần 0, có thể xem như cắt đuôi sau độ trễ này. Trong khi đó, PACF giảm dần từ từ theo các độ trễ. Do đó, mô hình trung bình trượt bậc 3 được lựa chọn cho phần phi mùa vụ, với $p = 0$ và $q = 3$.
- **Mô hình khả quan** : SARIMA(0,1,3)(0,1,1)₇.

So sánh giá trị AIC AICc BIC với các mô hình khác

```
m1 <- sarima(demand_ts_7, 0, 1, 3, 0, 1, 1, 7)
m2 <- sarima(demand_ts_7, 0, 1, 2, 0, 1, 1, 7)
m3 <- sarima(demand_ts_7, 1, 1, 3, 0, 1, 1, 7)
m4 <- sarima(demand_ts_7, 1, 1, 2, 0, 1, 1, 7)
```

Tiến hành chạy 4 mô hình trên và thu được bảng so sánh các chỉ số đo lường độ tốt của mô hình như sau:

Mô hình	Cấu trúc $(p, d, q)(P, D, Q)_s$	AIC	AICc	BIC	Ghi chú
m1	$(0, 1, 3)(0, 1, 1)_7$	20.66118	20.66120	20.67940	Tốt
m2	$(0, 1, 2)(0, 1, 1)_7$	20.68782	20.68784	20.70240	Thấp
m3	$(1, 1, 3)(0, 1, 1)_7$	20.662579	20.6626	20.68443	Tốt
m4	$(1, 1, 2)(0, 1, 1)_7$	20.66329	20.66331	20.68151	Khá

Bảng so sánh các tiêu chuẩn thông tin mô hình SARIMA

Nhận xét: Từ đó ta chọn mô hình SARIMA(0,1,3)(0,1,1)₇ là mô hình áp dụng cuối cùng

Chuẩn bị dữ liệu ngoại sinh

```
full_model <- lm(
  demand ~ min_temperature + max_temperature +
    solar_exposure + rainfall +
    school_day + holiday,
  data = train
)

summary(full_model)
```

```
Call:
lm(formula = demand ~ min_temperature + max_temperature + solar_exposure +
    rainfall + school_day + holiday, data = train)

Residuals:
    Min       1Q   Median       3Q      Max
-32187  -8140   -380    8357   47813

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  125999.68   1365.40   92.280 < 2e-16 ***
min_temperature   -576.40    108.21   -5.327 1.16e-07 ***
max_temperature    553.35     86.86    6.370 2.53e-10 ***
solar_exposure   -590.64     50.37  -11.727 < 2e-16 ***
rainfall        -260.92     80.49   -3.241 0.00122 **
school_day       485.32    765.53    0.634 0.52621
holiday        -17233.67   1778.43  -9.690 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12450 on 1450 degrees of freedom
Multiple R-squared:  0.1683,    Adjusted R-squared:  0.1648
F-statistic: 48.89 on 6 and 1450 DF,  p-value: < 2.2e-16
```

- **Nhận xét:** Biến `school_day` có giá trị p -value lớn hơn mức ý nghĩa 0,05, do đó không có ý nghĩa thống kê và được loại khỏi mô hình. Các biến còn lại có giá trị p -value nhỏ hơn 0,05, cho thấy có ý nghĩa thống kê và được giữ lại làm các biến ngoại sinh trong mô hình.

Chuẩn bị ma trận ngoại sinh

```
xreg_vars <- c(
  "min_temperature",
```

```

"max_temperature",
"solar_exposure",
"rainfall",
"holiday"
)

xreg_train <- as.matrix(train[, xreg_vars])
storage.mode(xreg_train) <- "numeric"
xreg_train <- scale(xreg_train)

xreg_test <- as.matrix(test[, xreg_vars])
storage.mode(xreg_test) <- "numeric"
xreg_test <- scale(
  xreg_test,
  center = attr(xreg_train, "scaled:center"),
  scale = attr(xreg_train, "scaled:scale")
)


```

Mô hình SARIMAX (Kết hợp mô hình SARIMA và biến ngoại sinh)

```

library(forecast)
model_sarimax <- Arima(demand_ts_7,
                        order = c(0,1,3),
                        seasonal = c(0,1,1),
                        xreg = xreg_train)

```




- **Nhận xét:** Dựa trên kết quả chẩn đoán mô hình SARIMAX $(0,1,3) \times (0,1,1)_7$:

- Đồ thị sai số chuẩn hóa (Standardized Residuals) cho thấy các sai số dao động ổn định quanh giá trị 0.

- Đồ thị ACF của sai số cho thấy không có sự tự tương quan đáng kể khi các hệ số nằm trong dải tin cậy.
- Đồ thị Q-Q Plot cho thấy phần dư xấp xỉ phân phối chuẩn dù có sai lệch nhẹ ở hai đầu.
- Tuy nhiên, các giá trị p -value của kiểm định Ljung-Box đều nhỏ hơn 0.05, cho thấy phần dư vẫn còn tương quan hệ thống và mô hình chưa đạt yêu cầu về nhiễu trắng.

Thể hiện time series data và predicted values (dựa trên mô hình xây dựng được) trên cùng một time plot

```
train_fitted <- fitted(model_sarimax)
plot(demand_ts_7, col = "black",
     main = "Dữ liệu quá khứ và giá trị fitted (training)",
     ylab = "Demand (MWh)")
lines(train_fitted, col = "red")
legend("topright",
     legend = c("Actual", "Fitted"),
     col = c("black", "red"),
     lty = 1)
```



• Nhận xét:

- Đồ thị cho thấy đường giá trị dự báo (Fitted - màu đỏ) bám sát rất tốt theo đường dữ liệu thực tế (Actual - màu đen) trong suốt toàn bộ khoảng thời gian quan sát.

- Mô hình đã mô phỏng thành công các đặc điểm quan trọng của chuỗi dữ liệu bao gồm xu thế biến động, tính chu kỳ và các đỉnh/đáy cục bộ của (Demand).
- Sai số giữa giá trị thực tế và giá trị khớp là tương đối nhỏ, cho thấy mô hình SARIMA $(0, 1, 3) \times (0, 1, 1)_7$ có khả năng giải thích tốt phương sai của dữ liệu trong quá khứ.
- Tuy nhiên, Việc khớp tốt trên dữ liệu huấn luyện không đồng nghĩa với việc dự báo tương lai luôn chính xác; cần kết hợp thêm các chỉ số đo lường sai số như MAE, MAPE để đánh giá khách quan hơn.

Dự báo cho nhu cầu sử dụng điện giai đoạn 01/01/2019 - 31/12/2019

```
options(scipen = 999)

forecast_2019 <- forecast(model_sarimax, xreg = xreg_test, level = 95)

n_train_display <- length(train$demand)


y_limit_min <- min(c(as.vector(train$demand), as.vector(forecast_2019$lower)))
y_limit_max <- max(c(as.vector(train$demand), as.vector(forecast_2019$upper)))

if(y_limit_min < 0) y_limit_min <- 0

plot(forecast_2019,
     include = n_train_display,
     ylim = c(y_limit_min, y_limit_max),
     main = " Bieu do du bao nam 2019",
     xlab = "Tuan",
     ylab = "Demand (MWh)",
     col = "blue",
     fcol = "red",
     flwd = 2)

legend("topleft",
     legend = c("Du lieu lich su (2015-2018)", "Du bao (Mean 2019)", "Khoang tin cay 95%"),
     col = c("blue", "red", "grey"),
     lty = c(1, 1, NA),
     fill = c(NA, NA, "grey"),
     border = "white",
     cex = 0.7)
```

Biểu đồ dự báo năm 2019



• **Nhận xét:**

- Nhận thấy giá trị dự báo khá không phù hợp so với dữ liệu từ tuần 1 tới hơn tuần 200
- Mô hình dự báo đi ngang xuống không có các đỉnh mùa vụ như dữ liệu lịch sử
- Phương sai cực kỳ lớn báo hiệu mô hình không phù hợp

So sánh giá trị dự báo với dữ liệu thực tế (testing dataset) giai đoạn 01/01/2019 - 31/12/2019

```
accuracy_metrics <- accuracy(forecast_2019, test$demand)
print(accuracy_metrics)
```

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	-42.05739	6262.707	4746.585	-0.2072293	3.949173	0.571777	0.009517607
Test set	21925.22876	25830.731	22237.880	17.9357658	18.234336	2.678791	NA

- **Nhận xét:** Mô hình cho thấy sai số nhỏ trên tập huấn luyện, tuy nhiên sai số trên tập kiểm tra tăng rất mạnh, đặc biệt RMSE và MAPE lớn. Điều này cho thấy mô hình chưa tổng quát tốt, có dấu hiệu overfitting hoặc chưa mô hình hóa đúng cấu trúc mùa vụ, nên độ tin cậy của dự báo ngoài mẫu còn hạn chế

```
predicted_demand <- as.numeric(forecast_2019$mean)

plot(test$date, test$demand,
     type = "l",
     col = "black",
     lwd = 1.5,
     main = "So sanh Nhu cau dien Thuc te vs Du bao (2019)",
```


```

xlab = "Tuần",
ylab = "Nhu cầu điện (MWh)",
ylim = range(c(test$demand, predicted_demand)))

lines(test$date, predicted_demand, col = "red", lwd = 1.5)

legend("topright",
      legend = c("Thực tế (Testing Data)", "Dự báo (Predicted Values)"),
      col = c("black", "red"),
      lty = 1,
      lwd = 2,
      cex = 0.8)

```



- **Nhận xét:** Đường dự báo theo sát xu hướng mùa vụ ngắn hạn nhưng luôn nằm thấp hơn dữ liệu thực tế trong phần lớn thời gian. Mô hình không bắt được các biến động mạnh và các đỉnh cao trong năm 2019, dẫn đến hiện tượng dự báo thiếu (underestimation) và sai số lớn trên tập kiểm tra.

Kiểm tra xem có phù hợp với mô hình GARCH hay không

```

library(FinTS)
res <- residuals(model_sarimax)
arch_result <- ArchTest(res, lags = 12)
print(arch_result)

```

```
ARCH LM-test; Null hypothesis: no ARCH effects  
data: res  
Chi-squared = 111.42, df = 12, p-value <  
0.00000000000000022
```

- **Nhận xét:** Kiểm định ARCH LM cho giá trị p-value rất nhỏ (nhỏ hơn 0.05), do đó bác bỏ giả thuyết không về việc không tồn tại hiệu ứng ARCH. Điều này cho thấy phần dư có hiện tượng phương sai thay đổi theo thời gian, vì vậy việc mô hình hóa phương sai bằng ARCH/GARCH là phù hợp và cần thiết

4. KẾT LUẬN


Mô hình SARIMA kết hợp các biến ngoại sinh cho kết quả tốt trên tập huấn luyện, tuy nhiên độ chính xác dự báo trên tập kiểm tra còn hạn chế. Kiểm định ARCH LM cho thấy tồn tại hiệu ứng phương sai thay đổi theo thời gian trong phần dư, vì vậy việc mở rộng mô hình theo hướng SARIMA–GARCH là cần thiết nhằm nâng cao độ tin cậy của dự báo ngoài mẫu.

Bài thực hành 3

1. Tìm và lựa chọn một time series dataset theo sự lựa chọn của bạn.
2. Nếu dữ liệu chưa sẵn sàng để phân tích, cần thực hiện các bước tiền xử lý dữ liệu cần thiết. (chẳng hạn: dữ liệu bị thiếu (missing data); dữ liệu bị trùng lặp; giá trị ngoại lai (outliers); ...)
3. Xây dựng **ARIMA** models hoặc **SARIMA** models
4. Thể hiện kết quả ước lượng cho các tham số và viết mô hình đầy đủ.
5. Thể hiện residuals plot, cũng như đồ thị hàm ACF và PACF của residuals và đưa ra nhận xét.
6. Dự báo, xây dựng và thể hiện khoảng tin cậy 95% tương ứng cho các giá trị dự báo này và đưa ra nhận xét.

1. Mô tả dữ liệu

- **Dữ liệu:** Sản lượng tiêu thụ khí tự nhiên tại Hoa Kỳ (U.S. Natural Gas Consumption).
- **Tần suất:** Dữ liệu theo tháng (Monthly) từ tháng 01/2019 đến tháng 08/2025.
- **Đơn vị tính:** Tỷ feet khối (Billion Cubic Feet - Bcf).
- **Nguồn dữ liệu:** U.S. Energy Information Administration (EIA).




Biểu đồ tiêu thụ khí tự nhiên tại Mỹ giai đoạn 2019 - 2025

2. Phân tích mã nguồn

```
data <- read.csv("F:/Du bao/Do an cuoi ki/data gas consumption.csv")

#Chuyen du lieu thanh chuoai thoi gian
ts_gas <- ts(data$Value, start = c(2019, 1), frequency = 12)
ts_gas
#Ve lai bang R
plot.ts(ts_gas,col = "dodgerblue", lwd = 2.5,
        main = "Monthly Consumption 2019 - 2025",
        xlab = "Year", ylab = "Value")
grid(15, 15, col = "gray")
```



- Các biểu hiện nổi bật:


- Chu kỳ lặp lại theo chu kỳ 12 tháng
- Đỉnh: Thường rơi vào tháng 12 và tháng 1 hàng năm
- Đáy: Rơi vào khoảng tháng 5 và tháng 6

⇒ **Nhận xét:** Có xu hướng tăng trưởng đều đặn

3. Vẽ đồ thị Monthplot

```
#Monthplot
```

```
monthplot(ts_gas, col = "dodgerblue", lwd = 2.5, col.base = "indianred",
          xlab = "Month", ylab = "Value")
grid(15, 15, col = "gray")
```




- Các biểu hiện nổi bật
 - Mức tiêu thụ có xu hướng tăng nhẹ qua các năm (đặc biệt các đỉnh sau cao hơn đỉnh trước).
 - Đồ thị lặp lại hình dạng sau mỗi chu kỳ 12 tháng (1 năm) —> Tính mùa vụ mạnh.
 - Trong mỗi năm, giá trị cao nhất vào đầu năm và thấp nhất vào khoảng giữa năm.

4. Xây dựng SARIMA models


- Khởi tạo x là time series data gốc, biểu thị yếu tố "xu hướng- trend" cùng với phương sai tăng dần.
- Thực hiện các phép biến đổi loại bỏ yếu tố xu hướng và kiểm tra tính dừng

```
lx = log(x) #Logarit
dlx = diff(lx) #Loại bỏ xu hướng
ddlx = diff(dlx, 12) #Loại bỏ mùa vụ
plot.ts(cbind(x, lx, dlx, ddx), main="Các bước biến đổi dữ liệu gas")
library(tseries)
adf_test <- adf.test(ddlx)
print(adf_test)
#Voi p-value = 0.01 < 0.05
```



Biểu đồ của chuỗi dữ liệu sau khi loại bỏ các yếu tố xu hướng và mùa vụ

```
par(mfrow=c(2, 1), mar=c(3, 3, 2, 1))
monthplot(dlx, main="Monthplot loại bỏ xu hướng")
monthplot(ddlx, main="Monthplot loại bỏ cả xu hướng và mùa vụ")
```




Biểu đồ monthplot của chuỗi dữ liệu sau khi loại bỏ các yếu tố xu hướng và mùa vụ

5. Xác định bậc phụ thuộc của mô hình

```
#Biểu đồ hàm ACF và PACF
library(astsa)
acf2(ddlx, 50)

#Ước lượng mô hình: sarima(du lieu_log, p, d, q, P, D, Q, S)
```

```
m1 <- sarima(lx, 1, 1, 1, 0, 1, 1, 12)
m2 <- sarima(lx, 0, 1, 1, 0, 1, 1, 12)
m3 <- sarima(lx, 1, 1, 0, 0, 1, 1, 12)
```



Hàm ACF và PACF của dữ liệu sau hai lần differencing.

Đánh giá và lựa chọn mô hình tối ưu

Tiến hành chạy 3 mô hình trên và thu được bảng so sánh các chỉ số đo lường độ tốt của mô hình như sau:

Mô hình	Cấu trúc $(p, d, q)(P, D, Q)_{12}$	AIC	AICc	BIC	Ghi chú
m1	$(1, 1, 1)(0, 1, 1)_{12}$	-3.381711	-3.376025	-3.250087	Tốt
m2	$(0, 1, 1)(0, 1, 1)_{12}$	-3.411552	-3.408754	-3.312835	Tốt nhất
m3	$(1, 1, 0)(0, 1, 1)_{12}$	-3.17314	-3.170341	-3.074422	Thấp

Bảng so sánh các tiêu chuẩn thông tin mô hình SARIMA

Nhận xét: Dựa vào Bảng trên, mô hình **m2** có chỉ số AIC và BIC thấp nhất. Do đó, nhóm lựa chọn mô hình này để tiến hành dự báo cho các giai đoạn tiếp theo.

```
best_model <- m2
```

- Thể hiện kết quả ước lượng cho các tham số trong mô hình.

Mô hình SARIMA $(0, 1, 1)(0, 1, 1)_{12}$ có dạng

$$(1 - B)(1 - B^{12})\ln(X_t) = (1 + \theta_1 B)(1 + \Theta_1 B^{12})W_t,$$

Chạy mô hình m2 ta được bảng sau:

Coefficients:

	Estimate	SE	t.value	p.value
ma1	-0.8427	0.0697	-12.0834	0e+00
sma1	-0.6238	0.1558	-4.0041	2e-04

sigma^2 estimated as 0.001584019 on 65 degrees of freedom

AIC = -3.411552 AICc = -3.408754 BIC = -3.312835

=> Từ đó ta được phương trình


$$(1 - B^{12})(1 - B)X_t = (1 - 0.8427B)(1 - 0.6238B^{12})W_t,$$

7. Thể hiện residuals plot, đồ thị hàm ACF và PACF của residuals.

Sau khi chạy đoạn mã:

```
m2 <- sarima(lx, 0, 1, 1, 0, 1, 1, 12)
```

Ta được đồ thị hàm ACF và PACF của residuals như sau:



• **Nhận xét:**

- **Standardized Residuals:** Phần dư dao động ổn định quanh giá trị 0, không có dấu hiệu thay đổi theo thời gian.
- **ACF of Residuals:** Các vạch đều nằm trong hai đường đứt đoạn màu xanh, có một vài vạch nhỏ nhẹ nhưng không đáng kể.
- **Normal Q-Q Plot:** Các điểm dữ liệu bám sát đường thẳng, chứng tỏ phần dư tuân theo phân phối chuẩn.


- **p-values for Ljung-Box Statistic:** Toàn bộ các giá trị p-value đều nằm trên đường đứt đoạn.
=> Phần dư (residuals) là white noise và mô hình được lựa chọn là phù hợp.

8. Đưa ra giá trị dự báo cho 12 tháng tiếp theo, xây dựng và thể hiện khoảng tin cậy 95

```
fore = sarima.for(lx, n.ahead = 12, 0, 1, 1, 0, 1, 1, 12)

predicted_values = exp(fore$pred)
lower_bound = exp(fore$pred - 1.96 * fore$se) #Khoang tin cay duoi 95%
upper_bound = exp(fore$pred + 1.96 * fore$se) #Khoang tin cay tren 95%

print(predicted_values)
```



• Nhận xét về độ phù hợp và khoảng dự báo:

- Khoảng tin cậy 95% ôm sát đường dự báo cho thấy mô hình có độ chính xác cao và sai số dự báo thấp.
- Khoảng dự báo không bị quá rộng theo thời gian, chứng tỏ tính ổn định của mô hình SARIMA(0,1,1)(0,1,1)₁₂ trong ngắn hạn.

```
> print(predicted_values)
      Jan      Feb      Mar      Apr      May      Jun      Jul      Aug
2025
2026 3783.613 3188.626 2893.801 2447.711 2353.714 2443.484 2751.094 2711.349
      Sep      Oct      Nov      Dec
2025 2402.855 2466.987 2813.770 3362.705
2026
```


Kết quả dự báo sản lượng gas 12 tháng tiếp theo với khoảng tin cậy 95%

• Thực hiện vẽ biểu đồ so sánh giữa giá trị thực tế và giá trị khớp

```
#1. Trích phần dư (residuals) từ mô hình SARIMA
res <- best_model$fit$residuals

#2. Tính giá trị khớp
fitted_values <- exp(lx - res)
```

```
#3. Vẽ đồ thị so sánh
plot(ts_gas, col = "dodgerblue", lwd = 2,
     main = "Observed values and Predicted values",
     xlab = "Time", ylab = "Gas Consumption")
#
lines(fitted_values, col = "red", lwd = 1.5)
#
grid(10, 10, col = "gray")
```



Dữ liệu thực tế so với dữ liệu từ mô hình SARIMA

Khoảng tin cậy $(1 - \alpha)$ cho giá trị dự báo X_{n+m}^n được xây dựng dưới dạng

$$\hat{X}_{n+m}^n - c_{\alpha/2} \sqrt{P_{n+m}} \leq X_{n+m}^n \leq \hat{X}_{n+m}^n + c_{\alpha/2} \sqrt{P_{n+m}},$$

Khi kích thước mẫu n đủ lớn, phương sai sai số dự báo P_{n+m} được xấp xỉ bởi

$$\hat{P}_{n+m}^n = \hat{\sigma}_W^2 \sum_{j=1}^{m-1} \psi_j^2.$$

Công thức trên khi m tăng, số lượng các số hạng trong tổng cũng tăng, dẫn đến giá trị $\hat{P}_{n+m}^n$ tăng theo, làm cho khoảng tin cậy ngày càng mở rộng.

Áp dụng kết quả trên cho mô hình dự báo tiêu thụ gas theo tháng, việc các khoảng tin cậy 95% mở rộng dần theo thời gian dự báo là đúng với công thức lý thuyết đã trình bày. Đồng thời, cho thấy mô hình dự báo là ổn định và các giá trị dự báo trung tâm vẫn có ý nghĩa thực tiễn.

V Tài liệu tham khảo

- [1] Robert H. Shumway & David S. Stoffer, *Time Series Analysis and Its Applications*. <https://drive.google.com/drive/u/0/folders/1tAgEZQv5k8E3lfR3GZnHMPRhDkaDlBtq>
- [2] OpenAI, *ChatGPT*. <https://chat.openai.com>
- [3] U.S. Energy Information Administration (EIA), *Independent Statistics and Analysis*. <https://www.eia.gov/totalenergy/data/browser/index.php?tbl=T04.01>